Previsão de Enchentes na Região Sudeste

Rodrigo Touma Costa - 2510583
Eduardo Luiz Meireles - 2510502
Pedro Monteiro Bernardes - 2510962
Daniel Santana Souza - 2310995
Raphael Vincenzo Maniero - 2510285

1. Introdução

1.1 Motivação

De acordo com dados oficiais do Centro Nacional de Monitoramento e Alertas de Desastres Naturais (CEMADEN), a Região Sudeste registrou cerca de 50% de todos os desastres naturais registrados no país em 2025. Dentre esse percentual, 56% foram devidos a eventos hidrológicos extremos.
Ainda, segundo o CEMADEN, em fevereiro de 2026, a Zona da Mata Mineira registrou um episódio de enchentes e deslizamentos que resultou em 74 óbitos, consolidando-se como o quarto maior desastre causado por chuvas no Brasil na última década.
Com isso, observa-se uma necessidade de estudar e elaborar medidas que ajudem a compreender o problema em questão, a fim de desenvolver um modelo que permita realizar a previsão desses eventos e reduzir os índices de óbitos e destruições que ocorreram nos últimos tempos.

1.2 Questão de Pesquisa

É possível prever o risco de enchentes em municípios da região Sudeste do Brasil, com antecedência suficiente para apoiar ações preventivas, a partir de dados históricos de chuva e de nível/vazão dos rios?

1.3 Cliente a Ser Atendido

O cliente do projeto será o Ministério do Meio Ambiente e Mudança do Clima, órgão responsável por alocar recursos federais nos diferentes estados brasileiros, de acordo com suas necessidades. Dessa forma, nosso projeto poderá gerar valor para o cliente dando suporte a essas decisões, ao indicar a possibilidade de enchentes nos estados do Sudeste brasileiro. O Ministério poderá, com o auxílio do DataCast, estimar com maior precisão as quantias financeiras que cada estado da região necessitará para lidar com enchentes.

1.4 Objetivo

O objetivo geral do projeto é desenvolver um modelo capaz de prever o risco de enchente nos municípios do Sudeste com alguns dias de antecedência, a partir do histórico de chuva e do comportamento do nível e da vazão dos rios.

Para isso, será necessário integrar as bases do INMET, do CEMADEN e da ANA em uma tabela única por município, data e hora; criar variáveis de chuva acumulada e defasada, que acompanham o tempo de resposta das bacias; definir o critério de cheia a partir do percentil local

da vazão, já que cada rio possui sua própria escala; equilibrar as classes por sobreamostragem; e treinar modelos avaliados por métricas sensíveis aos eventos raros, e não por acurácia.

O resultado esperado é oferecer ao Ministério do Meio Ambiente e Mudança do Clima uma base para destinar recursos antes da enchente, de acordo com o risco de cada localidade, em vez de agir apenas após a ocorrência do desastre.

1.5 Expectativa de Resultados

Espera-se que o modelo consiga identificar as cheias nos 52 municípios com estação fluviométrica, e que a variável de maior peso na previsão seja a chuva acumulada, e não a chuva da hora. A análise exploratória aponta nessa direção: na escala horária a correlação com a vazão é quase nula, mas cresce conforme a janela de acumulação aumenta, chegando a 0,607 em sessenta dias.

A maior dificuldade deve ser a escassez de exemplos de cheia, o que provavelmente resultará em um modelo com bom recall e precisão apenas moderada. Para este problema isso é aceitável, já que deixar de prever uma enchente custa muito mais do que mobilizar equipes desnecessariamente.

Por fim, espera-se demonstrar que os dados públicos brasileiros já são suficientes para gerar um indicador de risco municipal com utilidade prática, e que a principal limitação não está no algoritmo, mas na cobertura da rede de monitoramento.

2. Obtenção e Tratamento dos Dados

2.1 Justificativa para a Escolha dos Dados/Atributos

Os atributos escolhidos, retirados das bases de dados do INMET, CEMADEN e ANA, fornecem informações meteorológicas, pluviométricas e hidrológicas sobre o Sudeste brasileiro. Esses três fatores foram escolhidos porque, juntos, determinam a ocorrência de enchentes, o fenômeno abordado pelo projeto. As condições meteorológicas, disponibilizadas pelo INMET, propiciam ou dificultam a ocorrência de chuvas. Consequentemente, os dados do CEMADEN verificam a ocorrência ou não de eventos pluviais. Por fim, as informações de vazão e nível de rios, fornecidas pela ANA permitem analisar as consequências da chuva: o aumento dos níveis dos rios e, portanto, enchentes. Desse modo, os principais fatores que determinam a ocorrência ou não de enchentes são englobados pelos dados escolhidos.

2.2 Fontes dos Dados

Neste projeto, os dados são obtidos a partir de três fontes públicas de extrema excelência e confiabilidade:

2.2.1 INMET
O Instituto Nacional de Meteorologia (INMET) foi criado, primariamente, em 18 de novembro de 1909 pelo presidente da República Nilo Peçanha, com o nome de Diretoria de Meteorologia e Astronomia. O INMET representa o Brasil junto à Organização Meteorológica Mundial (OMM) e, por delegação desta Organização, é responsável pelo tráfego das mensagens coletadas pela rede de observação meteorológica da América do Sul e os demais centros meteorológicos que compõem o Sistema de Vigilância Meteorológica Mundial. O órgão também teve uma atuação absolutamente central na previsão, monitoramento e mitigação de danos na inundação histórica

do Rio Grande do Sul em 2024, publicando o primeiro boletim oficial indicando iminência de chuvas severas no estado.

2.2.2 CEMADEN

O Centro Nacional de Monitoramento e Alertas de Desastres Naturais (CEMADEN) foi criado pelo governo federal brasileiro em 1º de julho de 2011, por meio do Decreto nº 7.513. O CEMADEN abriga e sedia reuniões presenciais do Comitê Permanente sobre Redução de Risco de Desastres e Serviços de Alerta Precoce (SC-DRR) da OMM. Além disso, o órgão brasileiro também foi escolhido para liderar e desenvolver os acordos de cooperação em ciência, tecnologia e inovação voltados para a prevenção e mitigação de desastres naturais entre Brasil, Rússia, Índia, China e África do Sul. Semelhante ao INMET, o CEMADEN também atuou nas enchentes que infringiram o estado do Rio Grande do Sul em 2024, emitindo múltiplos alertas com dias de antecedência (classificados de moderados a muito altos) informando sobre o volume recorde de chuvas que inundou Porto Alegre e dezenas de municípios.

2.2.3 ANA

A Agência Nacional de Águas e Saneamento Básico (ANA) foi criada pelo Governo Federal do Brasil através da Lei nº 9.984, sancionada em 17 de julho de 2000. O órgão integra programas como a ONU-Meio Ambiente (PNUMA), o Programa das Nações Unidas para o Desenvolvimento (PNUD) e a UNESCO, atuando como ponto focal técnico, autoridade de monitoramento de dados e polo de cooperação (Hub) para a América Latina e países de língua portuguesa. A ANA atuou de forma estratégica na mitigação de danos durante as cheias na bacia do Rio Doce em 2020. A agência estruturou projeções hidrológicas com forte margem de antecedência, enquadrando os níveis de perigo de moderados a críticos para sinalizar a gravidade da situação. Essa transmissão contínua de dados preditivos forneceu o suporte técnico necessário para que Governador Valadares e dezenas de outras localidades mineiras e capixabas gerenciassem o impacto do transbordamento recorde de seus rios.

2.3 Procedimentos de Limpeza/Transformação/Redução

A partir da base integrada, foram aplicados os seguintes tratamentos, em sequência:

- Correção de coluna duplicada: a variável de radiação global aparecia com duas grafias distintas (KJ/m² e Kj/m²) por inconsistência de origem no cabeçalho do INMET entre anos; as duas foram unificadas em uma única coluna.
- Agregação de estações duplicadas: quando mais de uma estação do mesmo município reportava dados na mesma hora, os valores foram agregados pela média, eliminando duplicatas de chave (município + UF + data + hora).
- Tratamento de valores ausentes: variáveis meteorológicas contínuas (temperatura, pressão, umidade, vento, radiação, cota e vazão) tiveram lacunas de até 6 horas preenchidas por interpolação linear dentro de cada município. A precipitação (INMET e CEMADEN) foi deliberadamente excluída da interpolação e mantida como ausente, por ser uma variável de natureza mais irregular, para a qual interpolar poderia introduzir chuva artificial onde não choveu.
- Filtragem por limites físicos plausíveis: valores fora de faixas fisicamente possíveis (por exemplo, pressão atmosférica fora de 860–1050 mB, radiação fora de 0–4000 KJ/m², chuva fora de 0–400 mm/h) foram marcados como ausentes, tratando-os como erro de sensor/transmissão em vez de excluir a linha inteira.

O resultado final dessa etapa é o arquivo dataset_limpo_final.csv, que serve de base para a análise exploratória a seguir.

2.4 Tamanho da Base Final

Após a etapa de tratamento, a base de dados do projeto possui 7.458.432 linhas e 26 colunas. Antes da limpeza, o conjunto apresentava 15.688.560 linhas no total, o que indica que a etapa reduziu grandemente as dimensões da tabela.

2.5 Dicionário de Dados

A base de dados do projeto apresenta as seguintes variáveis:

- **municipio_norm**: texto; nome do município, maiúsculo, sem acento
- **UF**: texto; sigla do estado
- **data**: data; data da medição; AAAA-MM-DD
- **hora**: inteiro; hora em que ocorreu a medição (0 a 23); h
- **PRECIPITAÇÃO TOTAL, HORÁRIO (mm)**: numérico; volume de chuva acumulado; mm
- **PRESSAO ATMOSFERICA AO NIVEL DA ESTACAO, HORARIA (mB)**: numérico; pressão atmosférica medida na hora; mB
- **PRESSÃO ATMOSFERICA MAX. NA HORA ANT. (AUT) (mB)**: numérico; pressão atmosférica máxima registrada na hora anterior; mB
- **PRESSÃO ATMOSFERICA MIN. NA HORA ANT. (AUT) (mB)**: numérico; pressão atmosférica mínima registrada na hora anterior; mB
- **RADIACAO GLOBAL (KJ/m²)**: numérico; radiação solar global incidente na hora; KJ/m²
- **TEMPERATURA DO AR - BULBO SECO, HORARIA (°C)**: numérico; temperatura do ar medida na hora; °C
- **TEMPERATURA DO PONTO DE ORVALHO (°C)**: numérico; temperatura na qual o ar fica saturado de umidade; °C
- **TEMPERATURA MÁXIMA NA HORA ANT. (AUT) (°C)**: numérico; temperatura máxima da hora anterior; °C
- **TEMPERATURA MÍNIMA NA HORA ANT. (AUT) (°C)**: numérico; temperatura mínima da hora anterior; °C
- **TEMPERATURA ORVALHO MAX. NA HORA ANT. (AUT) (°C)**: numérico; temperatura de orvalho máxima da hora anterior; °C
- **TEMPERATURA ORVALHO MIN. NA HORA ANT. (AUT) (°C)**: numérico; temperatura de orvalho mínima da hora anterior; °C
- **UMIDADE REL. MAX. NA HORA ANT. (AUT) (%)**: numérico; umidade relativa máxima da hora anterior; %
- **UMIDADE REL. MIN. NA HORA ANT. (AUT) (%)**: numérico; umidade relativa mínima da hora anterior; %
- **UMIDADE RELATIVA DO AR, HORARIA (%)**: numérico; umidade relativa do ar medida na hora; %
- **VENTO, DIREÇÃO HORARIA (gr) (° (gr))**: numérico; direção do vento na hora (0 a 360); graus
- **VENTO, RAJADA MAXIMA (m/s)**: numérico; velocidade máxima de rajada de vento na hora; m/s
- **VENTO, VELOCIDADE HORARIA (m/s)**: numérico; velocidade média do vento na hora; m/s

- **chuva_cemaden_mm**: numérico; volume de chuva acumulado na hora (agregado de medições a cada 10 minutos); mm
- **cota_cm**: numérico; nível do rio na estação fluviométrica mais próxima (dado diário); cm
- **vazao_m3s**: numérico; vazão do rio na estação mais próxima (dado diário); m³/s
- **tem_estacao_cemaden**: booleano; indica se o município possui alguma estação do CEMADEN
- **tem_estacao_ana**: booleano; indica se o município possui alguma estação fluviométrica da ANA

3. Análise Exploratória dos Dados

3.1 Estatísticas Descritivas
A tabela abaixo resume as estatísticas descritivas (mínimo, máximo, média, mediana, desvio-padrão) e o percentual de valores ausentes de cada variável numérica na base limpa:

Variável	Mín	Máx	Média	Mediana	Desvio-padrão	Nulos	Nulos (%)
PRECIPITAÇÃO TOTAL HORÁRIO (mm)	0,0	131,0	0,15	0,0	1,25	1.133.977	15,2
PRESSÃO ATM. NÍVEL ESTAÇÃO (mB)	860,0	1032,7	951,66	949,6	37,47	579.120	7,8
PRESSÃO ATM. MÁX. HORA ANT. (mB)	720,3	1044,6	948,79	948,7	42,04	586.760	7,9
PRESSÃO ATM. MÍN. HORA ANT. (mB)	720,0	1032,4	948,27	948,2	42,08	586.760	7,9
RADIAÇÃO GLOBAL (KJ/m²)	0,0	9088,1	793,91	160,85	1046,62	702.065	9,4
TEMP. AR BULBO SECO (°C)	-9,0	42,9	22,32	22,2	5,3	566.930	7,6
TEMP. PONTO DE ORVALHO (°C)	-25,0	34,1	16,12	16,9	4,5	670.856	9,0
TEMP. MÁXIMA HORA ANT. (°C)	-8,0	43,5	23,03	22,8	5,43	574.523	7,7
TEMP. MÍNIMA HORA ANT. (°C)	-9,9	42,2	21,64	21,6	5,16	574.521	7,7
TEMP. ORVALHO MÁX. HORA ANT. (°C)	-25,0	35,3	16,71	17,5	4,45	679.838	9,1
TEMP. ORVALHO MÍN. HORA ANT. (°C)	-25,0	33,5	15,56	16,4	4,57	680.166	9,1
UMIDADE REL. MÁX. HORA ANT. (%)	7,0	100,0	74,5	79,0	19,46	678.978	9,1
UMIDADE REL. MÍN. HORA ANT. (%)	4,0	100,0	68,37	71,0	20,9	682.029	9,1
UMIDADE RELATIVA HORÁRIA (%)	4,0	100,0	71,49	75,0	20,32	670.908	9,0

Variável	Mín	Máx	Média	Mediana	Desvio-padrão	Nulos	Nulos (%)
VENTO DIREÇÃO HORÁRIA (° gr)	1,0	360,0	161,86	145,0	100,62	939.747	12,6
VENTO RAJADA MÁXIMA (m/s)	0,0	50,0	4,48	4,2	2,73	918.879	12,3
VENTO VELOCIDADE HORÁRIA (m/s)	0,0	19,6	1,72	1,5	1,45	912.559	12,2
chuva_cemaden_mm	0,0	111187,73	0,86	0,0	62,18	3.477.314	46,6
cota_cm	-145,0	1178,0	143,39	123,0	101,04	5.178.246	69,4
vazao_m3s	0,0	6805,93	107,57	13,45	318,52	5.126.226	68,7

Tabela 1 — Estatísticas descritivas das variáveis numéricas da base tratada (mínimo, máximo, média, mediana, desvio-padrão e percentual de valores ausentes).

A tabela com as estatísticas mostram padrões coerentes com o comportamento físico esperado em cada variável. As variáveis meteorológicas da fonte INMET (temperatura, pressão, umidade, vento e radiação) apresentam distribuições estáveis, com médias e medianas próximas, como por exemplo, a temperatura do ar varia de -9,0°C a 42,9°C, com média de 22,3°C e mediana de 22,2°C, e completude relativamente alta (7,6% a 12,6% de valores ausentes), refletindo falhas pontuais de sensor. Já a precipitação (INMET e CEMADEN) tem distribuição fortemente assimétrica: média próxima de zero (0,15 mm e 0,86 mm) mas mediana igual a zero e desvio-padrão relativamente alto, confirmando que a maior parte das horas não registra chuva e que os eventos de precipitação, quando ocorrem, são concentrados e intensos. As variáveis hidrológicas (cota_cm e vazao_m3s) apresentam os maiores percentuais de ausência (69,4% e 68,7%), decorrentes da cobertura geográfica limitada das estações ANA em relação ao total de municípios monitorados, e não de falha de sensor. No geral, a tabela indica um dataset consistente para as variáveis meteorológicas e mais esparso para as hidrológicas, um ponto relevante a considerar na seleção de municípios para as etapas seguintes de modelagem.

3.2 Análise de Dados Numéricos

Neste ponto, examinou-se a forma da distribuição de cada uma das 20 variáveis numéricas da base. O objetivo não é apenas descrever, mas identificar quais variáveis violam as premissas de simetria e homogeneidade que a maioria dos algoritmos assume, e quais apresentam comportamento que decorre da construção da base e não do fenômeno físico observado.

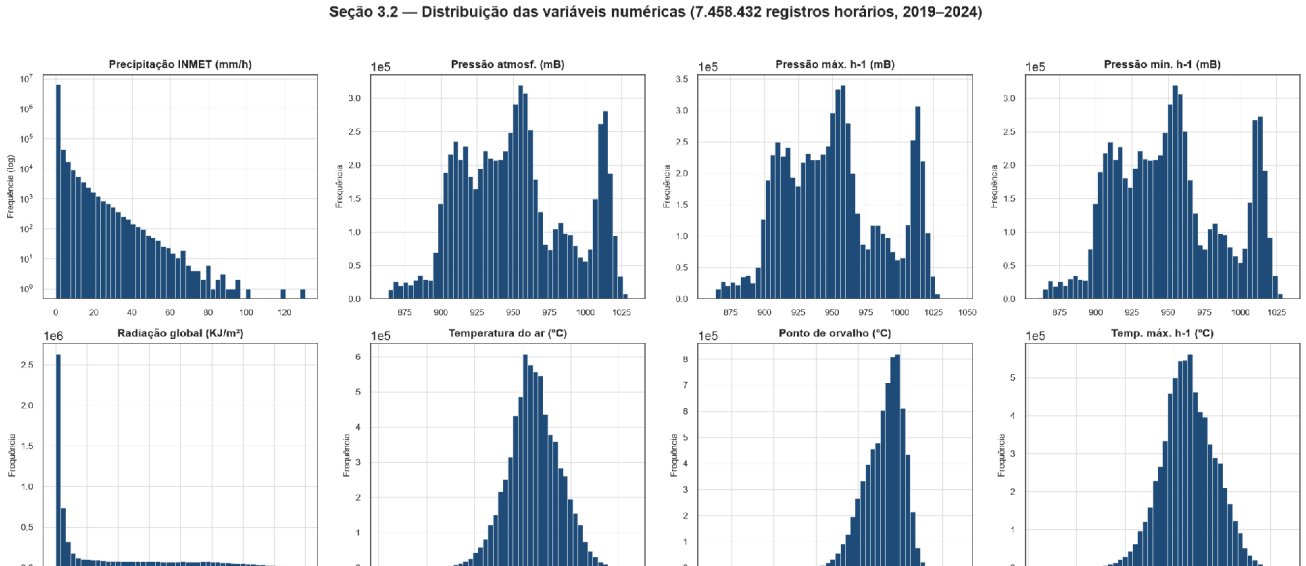


Figura 1 - Distribuição das 20 variáveis numéricas. As variáveis com assimetria superior a 3 em módulo (precipitação, chuva CEMADEN e vazão) estão em escala logarítmica no eixo vertical, sem a qual a barra do zero suprimiria visualmente todo o restante da distribuição.

A leitura do painel revela que as variáveis se organizam em quatro comportamentos distintos, tratados a seguir.

3.2.1 Precipitação: assimetria extrema e massa concentrada no zero

A precipitação é a variável mais problemática da base do ponto de vista estatístico, e também a mais importante para o projeto. Dos 6.324.455 registros horários válidos do INMET, 92,58% são exatamente zero e não chove na esmagadora maioria das horas. O coeficiente de assimetria é de 18,99 e a curtose de 568,22, valores que caracterizam uma distribuição radicalmente afastada da normalidade.

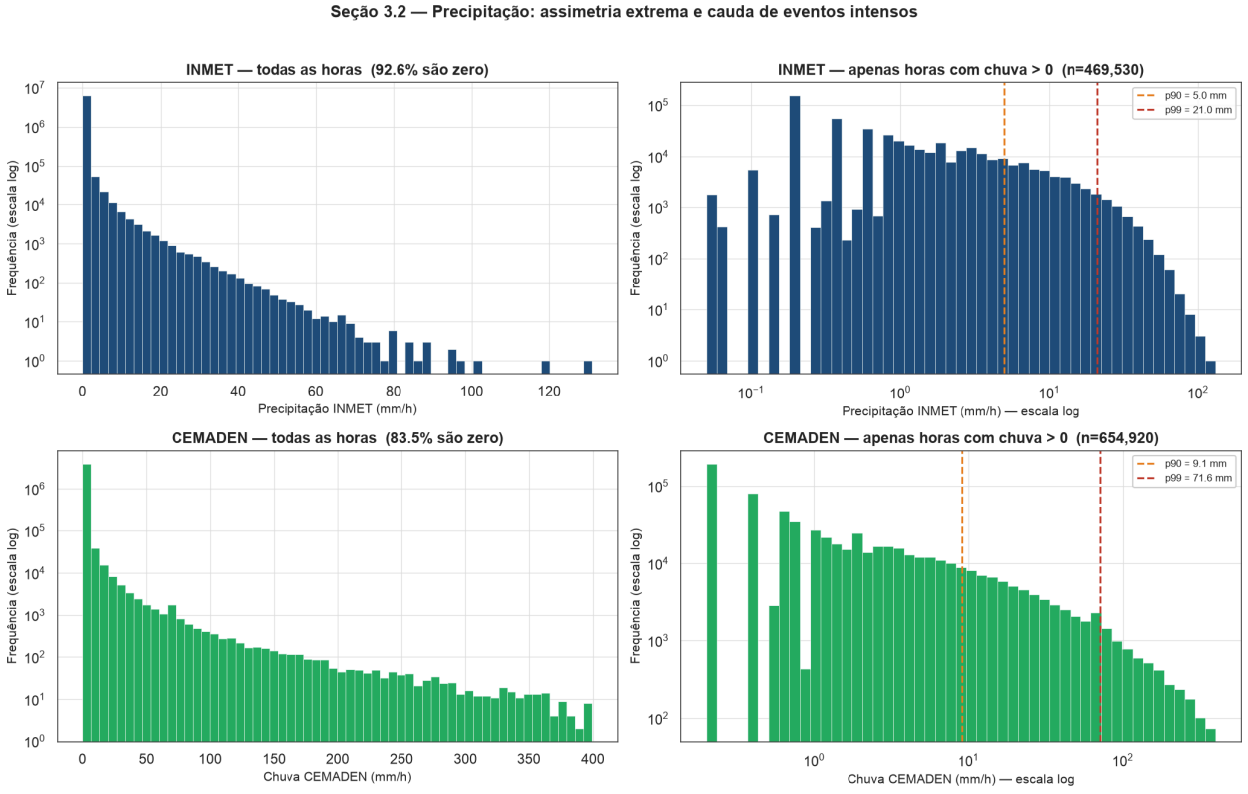


Figura 2 - Precipitação em duas leituras. À esquerda, todas as horas em escala logarítmica: a barra do zero é três ordens de grandeza maior que a barra seguinte. À direita, apenas as horas com chuva registrada, em escala log-log, onde a distribuição se revela aproximadamente exponencial. O padrão de "pente" nos valores baixos reflete a resolução de 0,2 mm do pluviômetro de báscula.

Ao isolar apenas as horas em que houve chuva (Figura 2, imagens à direita), a distribuição deixa de ser degenerada e assume forma aproximadamente exponencial. Os percentis condicionais quantificam a cauda:

Fonte	Horas com chuva	Mediana (>0)	p90 (>0)	p99 (>0)	Máximo	% das horas > 25 mm
INMET	469.530	0,6 mm	5,0 mm	21,0 mm	131,0 mm	0,047%
CEMADEN	654.920	0,8 mm	9,1 mm	71,6 mm	399,4 mm	0,603%

Tabela 2 — Distribuição condicional da precipitação, considerando apenas as horas com registro positivo. Os valores do CEMADEN são sistematicamente maiores; a Seção 3.4.4 demonstra que isso é um artefato de agregação, não um fenômeno meteorológico.

A consequência prática é direta. Uma métrica de erro médio, como o RMSE, será dominada pelos 92,58% de horas secas, e um modelo que sempre preveja "não chove" alcançaria acurácia aparentemente excelente sem qualquer utilidade operacional. O problema que o cliente precisa resolver está inteiramente contido na cauda direita, que representa menos de 0,05% das observações.

3.2.2 Variáveis hidrológicas: distribuição log-normal e cota negativa

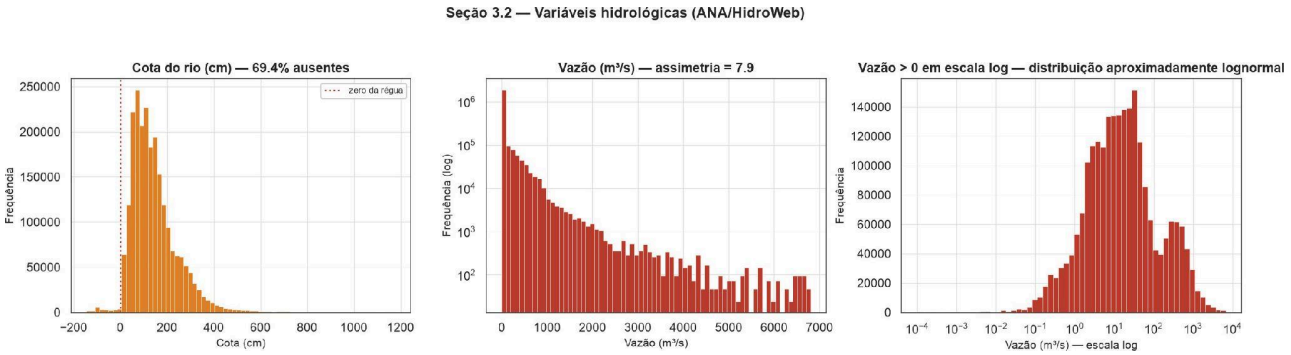


Figura 3 - Cota e vazão. A cota (esquerda) é aproximadamente simétrica em torno de 123 cm, com 0,91% de leituras negativas. A vazão em escala linear (centro) parece degenerada; em escala logarítmica (direita) revela-se aproximadamente lognormal.

A vazão apresenta assimetria de 7,91 e curtose de 97,32: a mediana é de apenas 13,5 m3/s, enquanto o percentil 99 chega a 1.408,9 m3/s e o máximo a 6.805,9 m3/s. Uma razão de mais de 500 vezes entre a mediana e o extremo. Contudo, o painel direito da Figura 3 mostra que essa assimetria desaparece sob transformação logarítmica, o que indica distribuição aproximadamente lognormal. Isso é uma boa notícia: diferentemente da precipitação, cuja massa em zero é irredutível, a vazão pode ser normalizada por uma transformação simples.

Um ponto que merece registro é a existência de 0,91% de valores negativos de cota, com mínimo de −145 cm. Não se trata de erro: a cota é medida em relação ao zero da régua linimétrica instalada na estação, referência arbitrária que pode estar acima do leito em períodos de estiagem severa. Esses valores foram corretamente preservados pela etapa de limpeza, que filtrou apenas faixas fisicamente implausíveis.

3.2.3 Variáveis meteorológicas contínuas

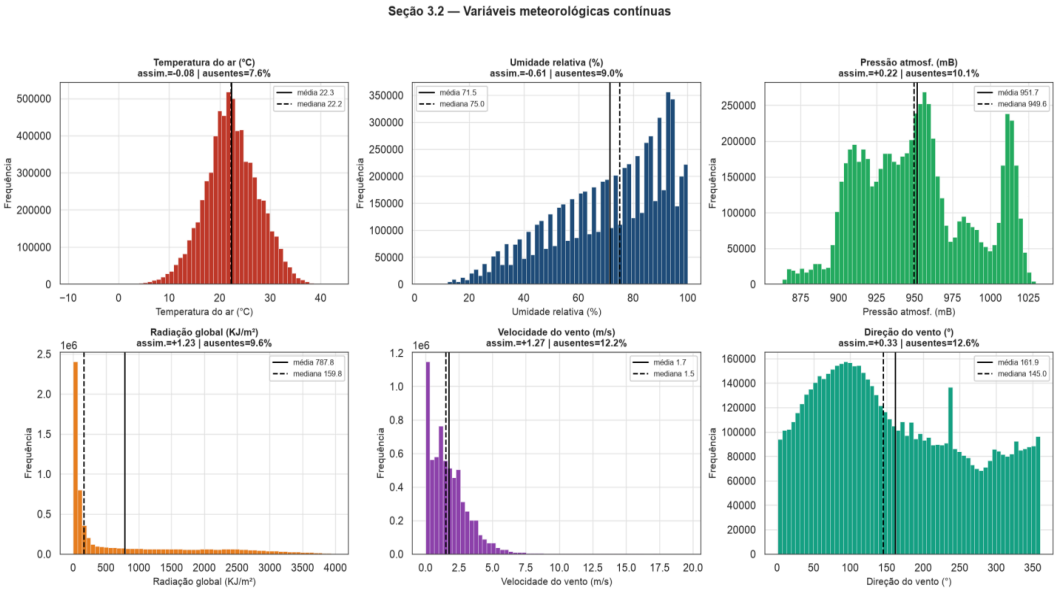


Figura 4 - Seis variáveis meteorológicas com médias e medianas assinaladas. A proximidade entre as duas medidas indica simetria; o afastamento, assimetria.

Temperatura do ar e umidade relativa comportam-se de forma próxima ao esperado. A temperatura é quase simétrica (assimetria −0,08), centrada em 22,3 °C, com amplitude de −9,0 °C a 42,9 °C compatível com a diversidade altimétrica do Sudeste. A umidade relativa é assimétrica à esquerda (−0,61) e acumula massa próximo de 100%, situação normal em noites de saturação do ar.

A radiação global merece leitura cuidadosa: 2,80% de valores exatamente zero e mediana de 159,8 KJ/mZ contra média de 787,8 KJ/mZ. A explicação não é estatística, mas física e a base é horária e inclui as horas noturnas, quando a radiação é legitimamente nula. A distribuição bimodal aparente é o ciclo dia-noite, e não uma anomalia. O teto de 4.000 KJ/mZ imposto pela limpeza afeta apenas 0,0013% dos registros.

A direção do vento, por sua vez, é a única variável genuinamente circular da base: 1° e 360° são fisicamente idênticos, mas numericamente distantes. Tratá-la como variável linear introduziria erro sistemático; a decomposição em componentes seno e cosseno é o tratamento adequado.

3.2.4 Pressão atmosférica: uma distribuição que mede altitude

O histograma da pressão na Figura 1 exibe um perfil claramente multimodal, com concentrações em torno de 910, 950 e 1.012 mB. Distribuições multimodais normalmente indicam mistura de subpopulações, e a investigação confirmou a hipótese de forma inequívoca.

3.3 Análise de Dados Categóricos

O dataset é composto, em sua maioria, por variáveis numéricas. No entanto, há quatro dados categóricos: UF, municipio_norm, tem_estacao_cemaden, tem_estacao_ana.

3.3.1 Distribuição por Unidade Federativa.

UF	Frequência	Percentual (%)
MG	3.524.736	47,3
SP	2.117.472	28,4
RJ	1.149.864	15,4
ES	666.360	8,9

Tabela 3 — Distribuição de linhas do dataset por Unidade Federativa (UF)

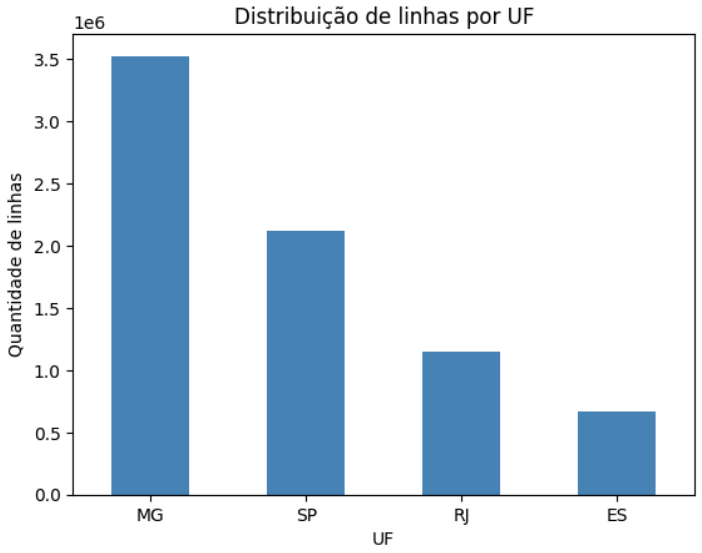


Figura 5 - Gráfico de barras que representa a frequência absoluta de cada estado da região Sudeste no dataset.

Desse modo, verifica-se que o estado de Minas Gerais é o que apresenta a maior concentração de registros de enchentes em detrimento dos demais, enquanto o Espírito Santo possui a menor.

3.3.2 Distribuição de tem_estacao_cemaden

Possui estação CEMADEN?	Quantidade de Municípios	Percentual (%)
True	86	58,9
False	60	41,1

Tabela 4 - Distribuição dos municípios do Sudeste segundo a presença de estação de monitoramento do CEMADEN

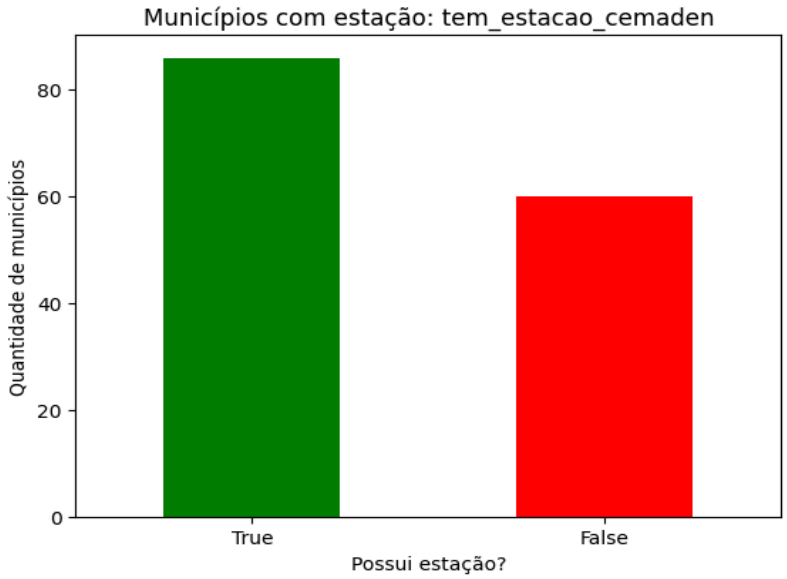


Figura 6 - Distribuição dos municípios da região Sudeste quanto a presença de estação do CEMADEN (True = possui estação; False = não possui)

3.3.3 Distribuição de tem_estacao_ana

Possui estação ANA?	Quantidade de Municípios	Percentual (%)
True	52	35,6
False	94	64,4

Tabela 5 - Distribuição dos municípios do Sudeste segundo a presença de estação de monitoramento da ANA/HidroWeb

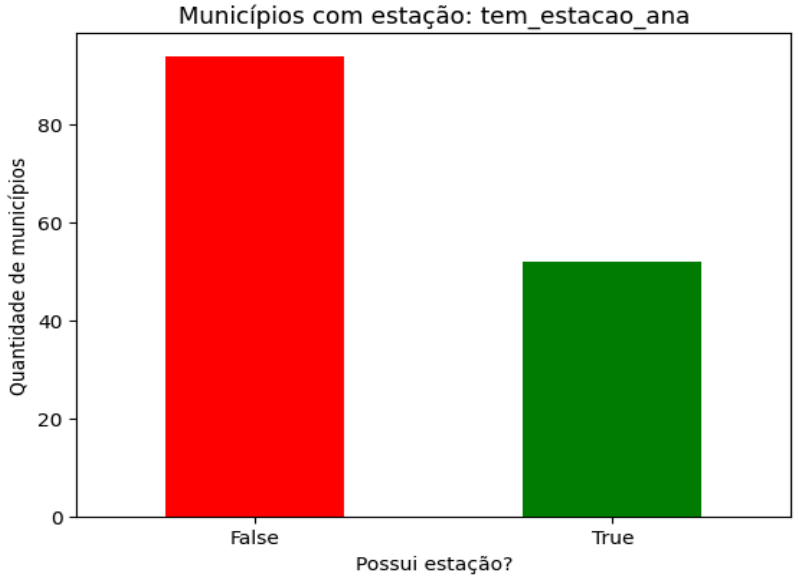


Figura 7 - Distribuição dos municípios da região Sudeste quanto a presença de estação da ANA/HidroWeb(True = possui estação; False = não possui)

3.3.4 Municípios com cobertura temporal incompleta

Município	Quantidade de Registros
Janaúba	17.544
Paty dos Alferes	18.792
Itatiaia	26.304
São Sebastião	26.304
Votuporanga	26.304
Pompéu	35.064
Sorocaba	35.064
Nova Venécia	35.064
Bebedouro	43.848
Ourinhos	43.848
São Simão	48.216

Tabela 6 - Quantidade de registros por município entre os que apresentam cobertura temporal incompleta (2019–2024)

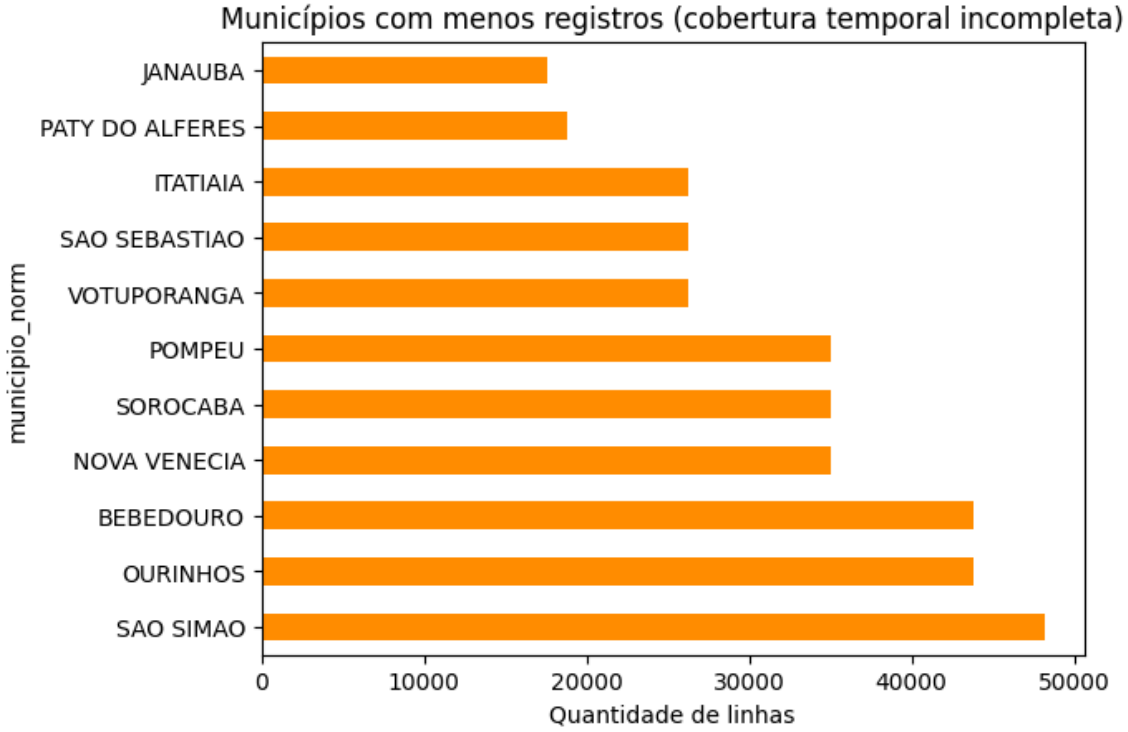


Figura 8 - Comparação visual da quantidade de registros entre os municípios com cobertura temporal

incompleta

O dataset em análise possui 146 municípios, porém 135 (92,5%) destes apresentam cobertura completa do período de 2019-2024, o que totaliza 52.608 registros horários cada um. Os 11 restantes, listados na Tabela 6, apresentam uma abrangência temporal incompleta, dado que os resultados apontam para número entre 17.544 e 48.216. Essa variação ocorreu possivelmente devido à desativação das estações meteorológicas antes do ano de 2024 se encerrar.

Com isso, na etapa de modelagem, deve ser levada em consideração essa limitação, já que o histórico disponível para a construção de padrões preditivos é reduzido. Consequentemente, a qualidade das previsões a respeito dos riscos de enchentes para essas localidades pode ser impactada se não receber a devida atenção.

3.4 Análise de Relações entre variáveis

Esta seção investiga como as variáveis se relacionam entre si, com atenção particular à relação entre precipitação e vazão — o par que sustenta a hipótese central do projeto. A análise combina correlação linear (Pearson) e monotônica (Spearman), gráficos de dispersão, séries temporais e distribuição espacial.

3.4.1 Matriz de correlação

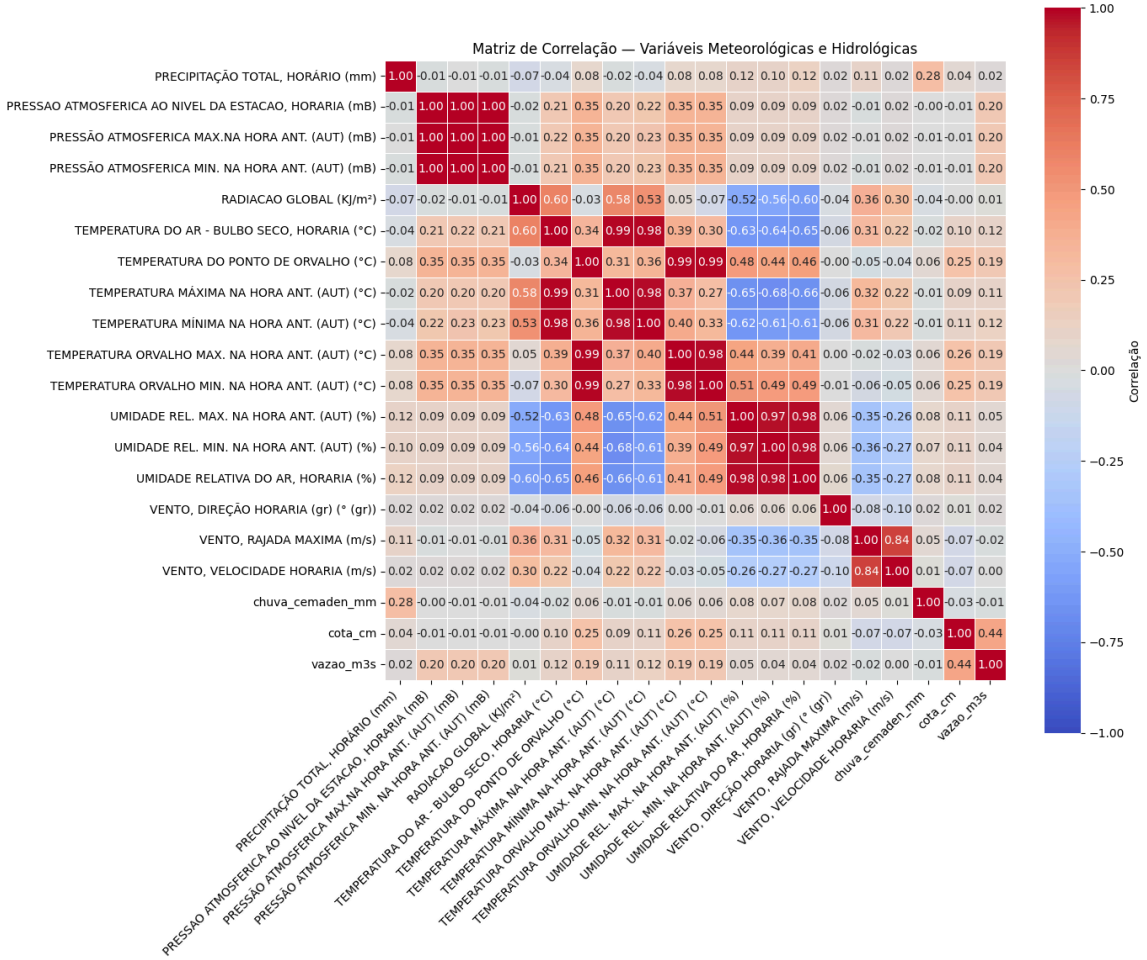


Figura 9 — Matriz de correlação de Pearson entre as 20 variáveis numéricas, calculada sobre a base completa.

A matriz não se distribui uniformemente: ela se organiza em blocos. Doze pares de variáveis apresentam correlação absoluta igual ou superior a 0,95, e três pares superam 0,99. Esses blocos correspondem a grupos em que a mesma grandeza física foi registrada em três colunas distintas — o valor instantâneo, o máximo da hora anterior e o mínimo da hora anterior.

Bloco redundante	Colunas	Faixa de correlação interna
Pressão atmosférica	3	r = 1,000 (indistinguíveis em duas casas decimais)
Temperatura do ar	3	r entre 0,982 e 0,988
Temperatura do ponto de orvalho	3	r entre 0,977 e 0,988
Umidade relativa	3	r entre 0,969 e 0,980
Vento (velocidade e rajada)	2	r = 0,844

Tabela 7 - Blocos de variáveis redundantes identificados pela matriz de correlação.

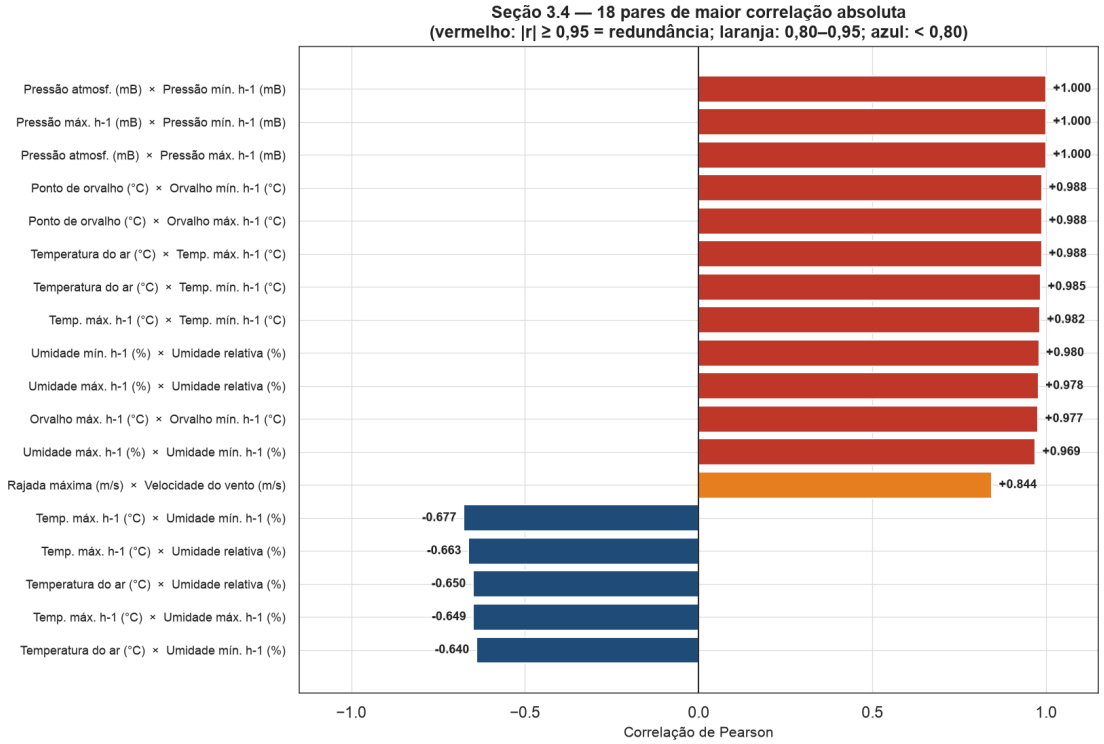


Figura 10 - Os dezoito pares de maior correlação absoluta. Em vermelho, os pares redundantes (|r| ≥ 0,95); em azul, os pares que carregam informação genuinamente distinta.

O caso da pressão é o mais extremo: as três colunas são estatisticamente indistinguíveis, o que faz sentido físico, já que a pressão varia lentamente e a diferença entre o valor instantâneo e os extremos da hora anterior é desprezível frente à sua amplitude total. Manter as três colunas em um modelo introduz multicolinearidade severa, que desestabiliza coeficientes em métodos lineares e distorce medidas de importância de variáveis em métodos baseados em árvores.

Fora dos blocos redundantes, a relação mais forte é a anticorrelação entre temperatura e umidade relativa (r = −0,650). É a única correlação alta da base que não decorre de duplicação de coluna: ela reflete o mecanismo físico pelo qual o aquecimento do ar aumenta sua capacidade de retenção de vapor, reduzindo a umidade relativa sem alteração da umidade

absoluta.

3.4.2 Gráficos de dispersão

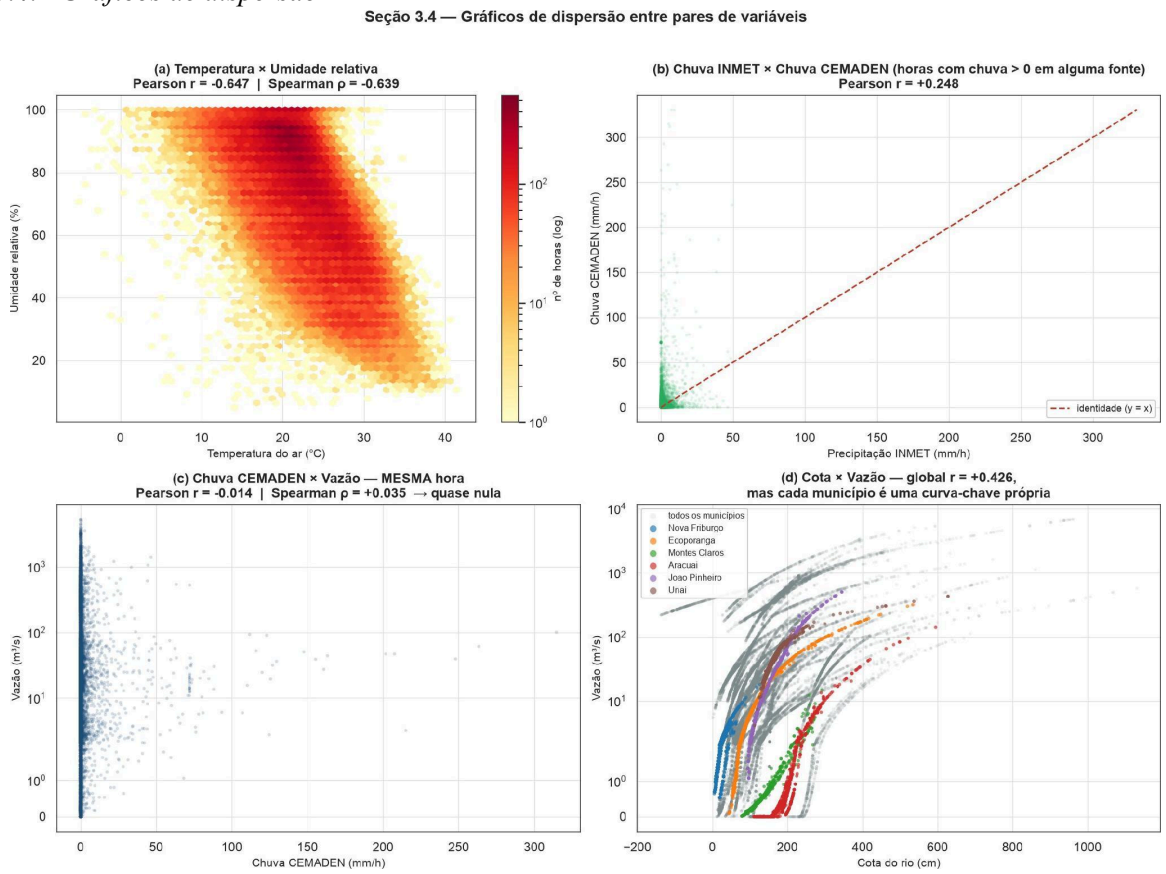


Figura 11 - Quatro pares de variáveis em dispersão. (a) temperatura × umidade em mapa de densidade hexagonal; (b) concordância entre as duas fontes de chuva; (c) chuva e vazão na mesma hora; (d) cota × vazão, com seis municípios destacados sobre o conjunto em cinza.

Painel (a): Temperatura × Umidade. A nuvem tem orientação descendente clara e formato de banda, não de elipse: a dispersão da umidade é muito maior nas temperaturas baixas (variando de 20% a 100%) do que nas altas. A relação, portanto, é forte mas não estritamente linear, e a proximidade entre Pearson (−0,647) e Spearman (−0,639) confirma que é ao menos consistentemente monotônica. O acúmulo na faixa de 100% de umidade é o teto físico do instrumento.

Painel (b): INMET × CEMADEN. As duas fontes medem a mesma grandeza em locais próximos, e a expectativa razoável seria que os pontos se alinhassem à reta de identidade. Não é o que se observa: a correlação de Pearson é de apenas 0,278 e a nuvem está sistematicamente deslocada para cima da diagonal, indicando que o CEMADEN registra valores muito superiores. A concordância binária de se houve ou não chuva é de 86,5%, bem melhor que a concordância de intensidade. A Seção 3.4.4 identifica a causa.

Painel (c): Chuva × Vazão. Este é o resultado mais contraintuitivo da análise. O par de variáveis que define o problema do projeto apresenta correlação praticamente nula na escala horária: Pearson de −0,014 e Spearman de +0,035. A nuvem de pontos é uma faixa vertical junto ao eixo para qualquer valor de chuva, o qual observa-se todo o espectro de vazões. A Seção 3.4.3 demonstra que a ausência de correlação é aparente e decorre da escala temporal escolhida.

Painel (d): Cota × Vazão. Globalmente a correlação é moderada (r = +0,426 na amostra), o que surpreende, já que vazão é calculada a partir da cota por meio da curva-chave da estação. Ao colorir seis municípios individualmente, a explicação torna-se visível: cada município traça sua

própria curva, nítida e monotônica, mas deslocada das demais. Uma cota de 200 cm corresponde a 1 m3/s num rio e a 300 m3/s em outro, pois a relação depende da geometria da seção do rio.

3.4.3 Defasagem e acumulação

A correlação nula entre chuva e vazão observada no painel (c) da Figura 8 exigia investigação, por contrariar tanto a hipótese do projeto quanto a hidrologia elementar. Duas hipóteses foram testadas: que a vazão responde à chuva com atraso, e que responde ao volume acumulado em vez da intensidade instantânea. Ambas se confirmaram.

Para isolar o efeito identificado na seção anterior, as correlações foram calculadas dentro de cada município e agregadas pela mediana, sobre séries diárias de 52 municípios com estação fluviométrica (111.792 pares município-dia).

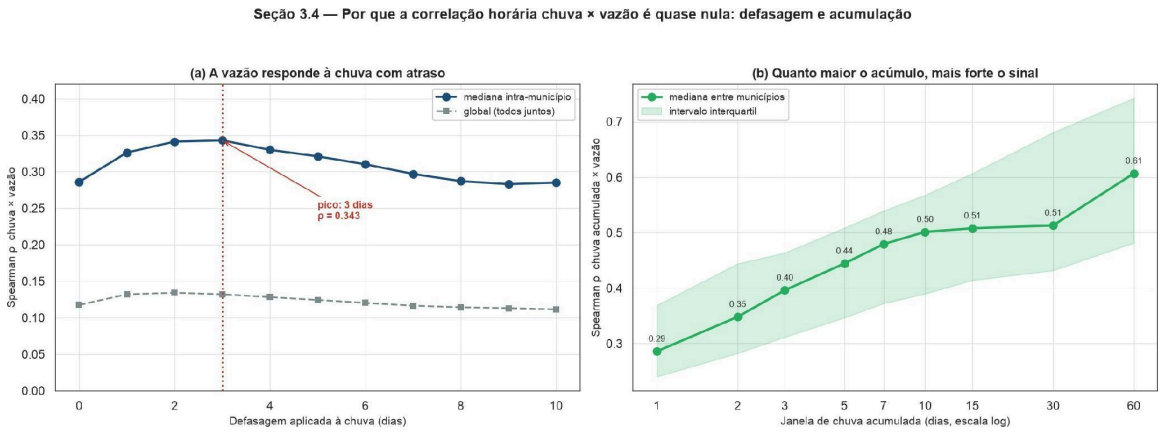


Figura 12 - (a) Correlação de Spearman entre chuva e vazão conforme a defasagem aplicada à chuva. (b) Correlação entre chuva acumulada em janelas crescentes e vazão do dia; a faixa sombreada é o intervalo interquartil entre municípios.

O painel (a) mostra que a correlação parte de ρ = 0,286 sem defasagem, atinge o máximo de ρ = 0,343 com três dias de atraso e decai lentamente a partir daí. A existência de um pico bem definido é a assinatura do tempo de concentração da bacia: a água precipitada leva dias para escoar pela superfície, infiltrar e alcançar a seção do rio onde a estação mede.

O painel (b) é ainda mais decisivo. Acumulando a chuva em janelas progressivamente maiores, a correlação cresce de forma monotônica:

Janela de acumulação	1 dia	3 dias	7 dias	15 dias	30 dias	60 dias
Spearman ρ (mediana intramunicipal)	0,286	0,396	0,479	0,508	0,513	0,607

Tabela 8 — Correlação entre chuva acumulada e vazão do dia. O sinal mais que dobra ao passar da chuva de um dia para o acumulado de dois meses.

3.4.4 Insight de integração na variável de chuva do CEMADEN

A discrepância entre INMET e CEMADEN observada no painel (b) da Figura 8 mostrou-se sistemática e quantificável. O volume total de chuva registrado pelo CEMADEN no período é 4,65 vezes o registrado pelo INMET nos mesmos município-horas, e o valor máximo da série chega a 399,4 mm em uma única hora — próximo do recorde mundial de precipitação horária, o que é implausível para 694 ocorrências distribuídas em 20 municípios.

A distribuição geográfica dessas ocorrências deu a pista decisiva: elas concentram-se em São Paulo (250 registros), Angra dos Reis (182), Rio de Janeiro (77) e Juiz de Fora (70), precisamente os municípios com as redes de monitoramento mais densas. Testou-se então a hipótese de que a agregação horária somou as leituras de todas as estações do município, em vez de calcular sua média.

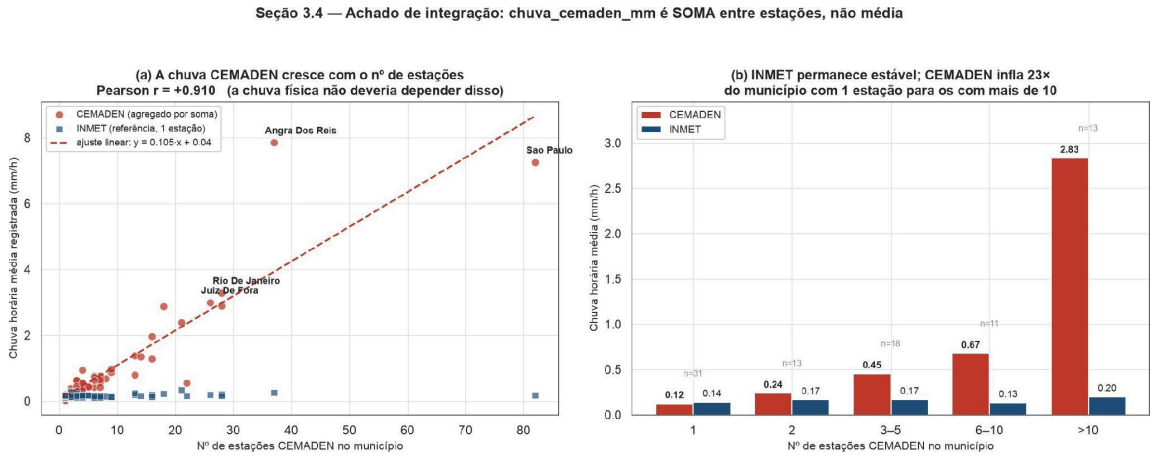


Figura 13 - (a) Chuva horária média registrada contra o número de estações CEMADEN do município, com o INMET como referência. (b) Comparação agregada por faixa de densidade de estações.

A correlação entre o número de estações CEMADEN de um município e a chuva horária média ali registrada é de r = +0,910 (Spearman ρ = +0,926), sobre 86 municípios. A precipitação é um fenômeno físico: a quantidade de chuva que cai não pode depender de quantos pluviômetros a medem.

A verificação pelo INMET confirma o diagnóstico. Municípios com uma única estação CEMADEN registram média de 0,12 mm/h; os com mais de dez estações registram 2,83 mm/h, o que representa 23 vezes mais. No mesmo recorte de municípios, a média do INMET permanece estável entre 0,14 e 0,20 mm/h, como esperado de um sensor único por município.

O caso extremo é São Paulo: com 82 estações, a base atribui ao município chuva horária média de 7,39 mm/h, equivalente a cerca de 64.700 mm anuais, aproximadamente quarenta vezes a precipitação real da cidade.

Consequentemente, a variável chuva_cemaden_mm não pode ser utilizada em sua forma atual, e qualquer modelo treinado com ela aprenderá a densidade da rede de sensores como se fosse intensidade de chuva. A correção exige refazer a agregação do CEMADEN substituindo a soma entre estações por média (ou máximo, se o objetivo for captar o núcleo mais intenso da célula de chuva), preservando a soma apenas entre as leituras de dez minutos de uma mesma estação dentro da hora.

Registre-se que este achado não invalida a etapa de integração como um todo: o cruzamento de chaves, a normalização de nomes de municípios e o alinhamento temporal funcionaram corretamente, como atesta a concordância binária de 86,5% entre as duas fontes quanto à ocorrência de chuva.

3.4.5 Séries temporais

Na análise temporal, examinamos dois municípios escolhidos por contraste: Juiz de Fora, em granularidade horária e recorte de um único ano (2023), e Nova Friburgo, em granularidade diária ao longo do período completo (2019–2024). A combinação permite observar tanto a resposta de curto prazo da bacia, impossível de ver na escala diária usada no restante do relatório, quanto o comportamento sazonal e interanual de longo prazo.

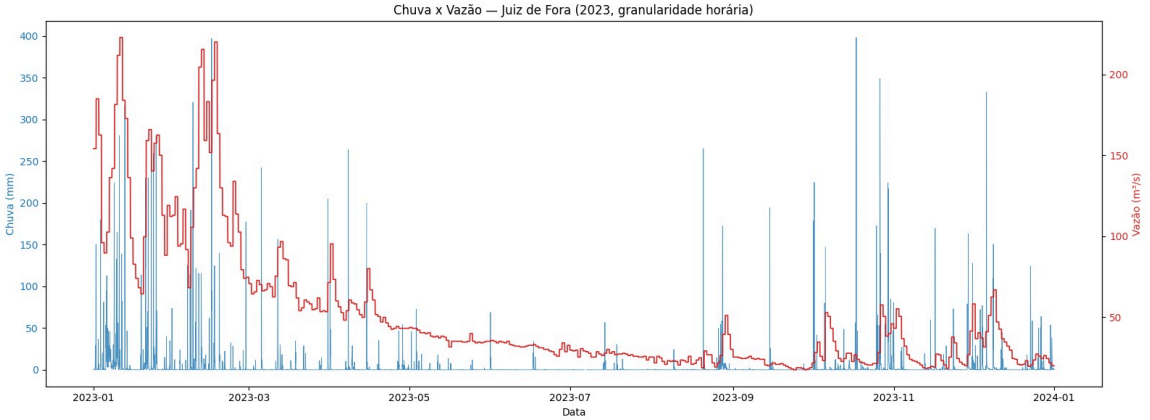


Figura 14 - Chuva e vazão horárias em Juiz de Fora (MG), 2023.

A escala horária revela uma estrutura que a agregação diária esconde. Logo no início de janeiro de 2023, um pico de chuva de aproximadamente 400 mm em uma única hora antecede o maior pulso de vazão do ano (aproximadamente 220 m³/s). Esse valor de chuva é o mesmo tipo de artefato identificado na Seção 3.4.4: Juiz de Fora está entre os municípios com rede CEMADEN mais densa, e a variável ali soma as leituras de todas as estações em vez de calcular a média, o que produz picos horários fisicamente implausíveis. A vazão, por outro lado, permanece em uma faixa compatível com a física do rio, o que reforça que a anomalia está na construção da variável de chuva, não no sinal hidrológico.

De março a agosto, a vazão diminui de forma lenta e quase monotônica, caindo de cerca de 50 para 20 m³/s, apesar de chuvas isoladas em abril e junho em que cada uma produz apenas uma oscilação pequena e de curta duração na vazão, sem alterar a tendência de recessão. É a mesma assinatura discutida na Seção 3.4.3: um evento de chuva isolado não move a vazão; o que move é o acúmulo de eventos sucessivos.

Esse acúmulo fica visível a partir de agosto: sucessivos episódios de chuva entre agosto e dezembro produzem uma série de "degraus" de subida na vazão de aproximadamente 20 para a faixa de 50–95 m³/s entre outubro e novembro, com nova recessão parcial antes de um último pulso em dezembro. O padrão em degraus, só visível na escala horária, é a evidência mais direta do mecanismo de saturação progressiva da bacia descrito qualitativamente na Seção 3.4.3.

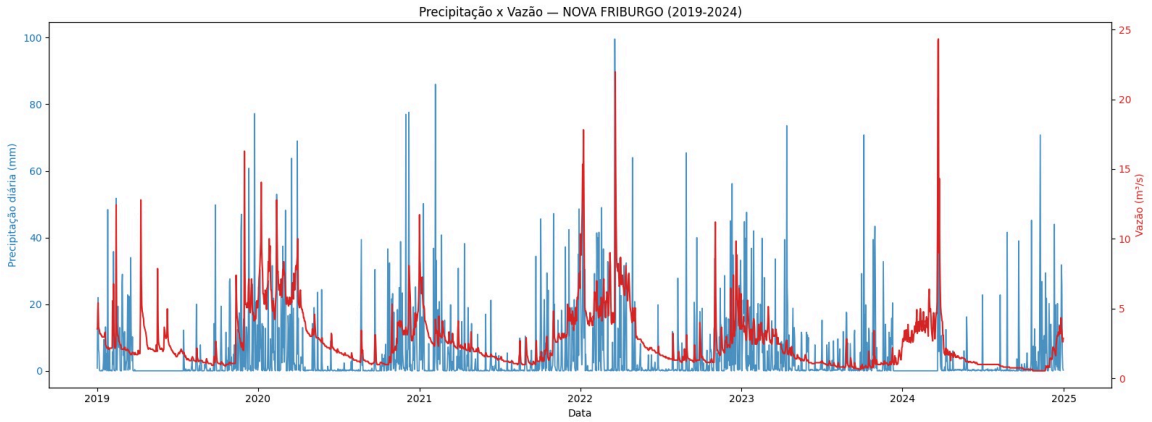


Figura 15 - Precipitação e vazão diárias em Nova Friburgo (RJ), 2019–2024.

Nova Friburgo ilustra a mesma dinâmica em escala diária e horizonte plurianual, mas numa bacia de porte muito menor: a vazão máxima do período não ultrapassa de aproximadamente 24 m³/s, uma ordem de grandeza abaixo de municípios de bacia maior como São Romão confirmação adicional de que cada rio tem sua própria escala (Seção 3.4.2) e de que comparações absolutas de vazão entre municípios não são informativas sem normalização pela bacia.

Os três padrões já descritos qualitativamente no relatório aparecem aqui com clareza: sazonalidade (picos concentrados entre dezembro e março, recessão até valores próximos de zero entre junho e setembro), assimetria do hidrograma (subida abrupta, recessão lenta em cada ciclo anual) e variabilidade interanual, evento de fevereiro/março de 2024 (aproximadamente 24 m³/s) que supera claramente os demais anos da série, com o segundo maior pico (aproximadamente 18 m³/s, início de 2022) já bem abaixo dele. Essa disparidade reforça a recomendação, já registrada na síntese do relatório, de particionar treino e validação por ano completo, e não por amostragem aleatória de observações.

3.4.6 Distribuição espacial

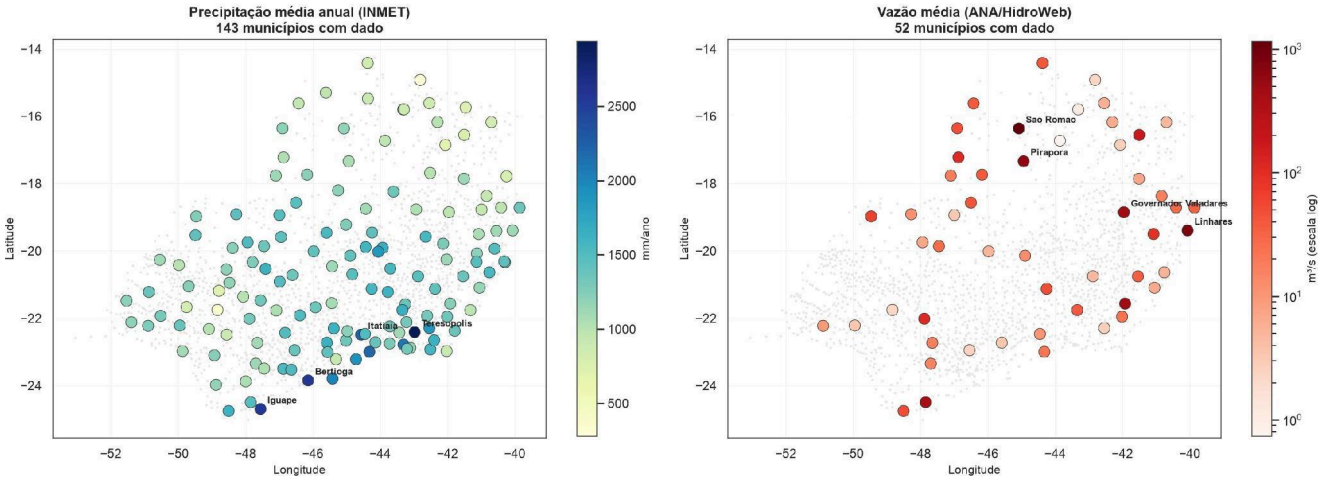


Figura 16 - Precipitação média anual e vazão média por município. Os municípios foram geocodificados por cruzamento com a tabela pública de coordenadas do IBGE (143 dos 146 municípios obtiveram correspondência).Os pontos cinza ao fundo são todos os municípios do Sudeste, e desenham o contorno da região.

O mapa de precipitação reproduz com fidelidade a climatologia conhecida do Sudeste. A faixa de maior precipitação acompanha a Serra do Mar, no litoral de São Paulo e Rio de Janeiro, Bertioga, Iguape, Itatiaia e Teresópolis lideram, onde a orografia força a ascensão do ar úmido oceânico. O quadrante norte de Minas Gerais apresenta os menores valores, consistente com sua transição para o semiárido. Esse gradiente noroeste-sudeste é uma validação relevante: a base reproduz um padrão climatológico independente, que não foi imposto por nenhuma etapa do processamento.
O mapa de vazão segue lógica distinta, e a comparação entre os dois é instrutiva. Os maiores valores não estão onde mais chove, mas onde a área de drenagem acumulada é maior, sendo São Romão e Pirapora, no médio São Francisco, e Linhares, na foz do rio Doce. A vazão é uma variável integrada no espaço, enquanto a precipitação é local. Isso reforça que a posição do município na bacia hidrográfica é uma variável explicativa ausente da base atual e potencialmente valiosa.

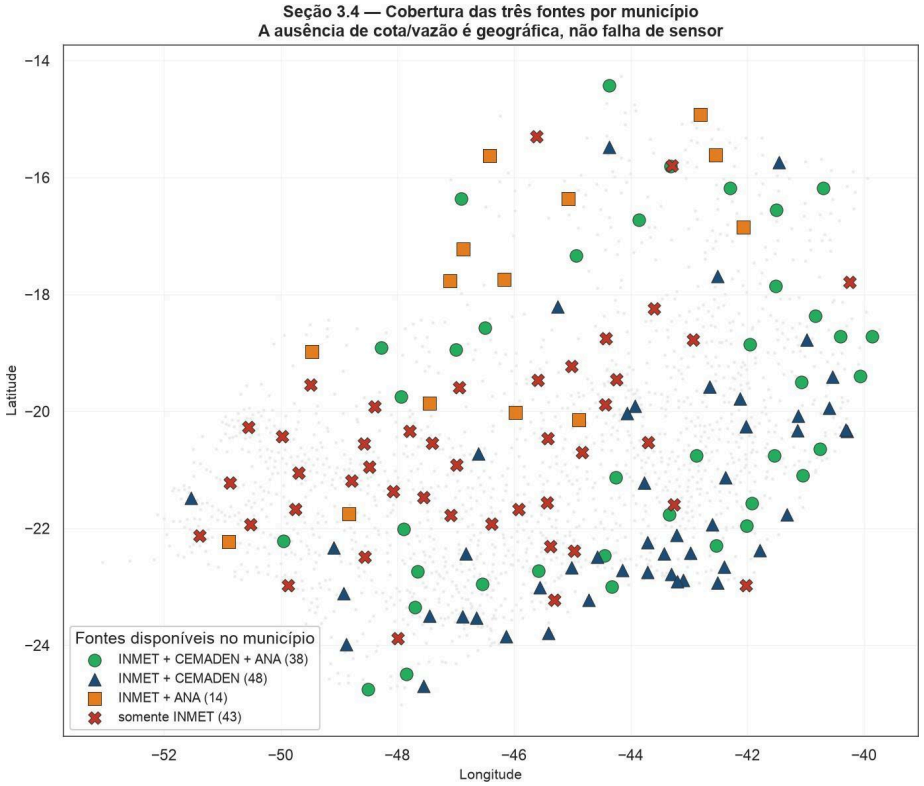


Figura 17 - Combinação de fontes disponíveis em cada município. A ausência de dados hidrológicos é uma característica geográfica da rede de monitoramento, não uma falha de medição.

O mapa de cobertura explica visualmente os percentuais de ausência discutidos na Seção 3.2.5. Apenas 38 dos 143 municípios geocodificados dispõem das três fontes simultaneamente; 43 contam somente com o INMET. Os municípios com estação da ANA concentram-se ao longo dos grandes eixos fluviais, o que é coerente com a finalidade da rede fluviométrica nacional.
Essa distribuição impõe uma restrição de escopo que precisa ser explicitada ao cliente: um modelo que preveja vazão só pode ser treinado e validado nos 52 municípios com dados hidrológicos. Estendê-lo aos demais exigiria uma estratégia de regionalização — transferir parâmetros de bacias monitoradas para bacias sem monitoramento —, o que constitui um problema metodológico distinto e de dificuldade consideravelmente maior.

3.4.7 Raridade dos eventos de interesse

A última relação relevante é entre o volume de dados e a quantidade de eventos efetivamente úteis ao objetivo do projeto. Adotando o percentil 99 local da vazão como limiar operacional de cheia, decisão baseada no critério que respeita a escala própria de cada rio, conforme exige o achado da Seção 3.4.2, obtém-se o seguinte quadro:

Definição de evento	Ocorrências	Total	Frequência	Proporção
Dia acima do p95 local de vazão	4.846	97.313 dias-município	4,98%	1 : 19
Dia acima do p99 local de vazão	982	97.313 dias-município	1,01%	1 : 98
Hora com chuva INMET acima de 25 mm	2.948	6.324.455 horas	0,047%	1 : 2.145

Tabela 9 — Frequência dos eventos extremos sob três definições operacionais.

De 7,4 milhões de registros horários, restam menos de mil dias-município que caracterizam cheia sob o critério mais restritivo. O volume bruto da base é enganoso: o que determina a viabilidade do modelo não é o número total de observações, mas o número de eventos positivos disponíveis para o aprendizado.

3.5 Insights Importantes
(Sintetizar os principais insights obtidos a partir da análise exploratória. Destacar padrões observados, variáveis relevantes, possíveis desafios e questões que surgiram durante a análise. Esses insights servirão de base para as próximas etapas do projeto.)

A análise exploratória dos dados demonstrou alguns padrões interessantes quanto aos registros das enchentes na Região Sudeste. Dentre eles, os principais estão relacionados à precipitação, à disparidade da cobertura e à correlação entre as variáveis.
O primeiro *insight* importante é sobre a precipitação total (primeiro histograma apresentado no tópico 3.2), que apresenta uma forte assimetria à direita, com mediana e média aproximadamente iguais a 0 mm e um desvio padrão relativamente alto. Essa análise permite notar que os eventos de chuva forte - que antecedem as enchentes - possuem uma certa raridade, dado todos os intervalos de horários obtidos. Desse modo, considera-se tratar o problema em questão como um caso de classes desbalanceadas: quando um conjunto de dados possui uma quantidade maior de exemplos de uma classe em detrimento de outra. Para tanto, uma solução é aplicar a técnica de *oversampling*, ou seja, um aumento da amostragem; em particular, das horas de chuvas extremas.
O segundo *insight* está relacionado à disparidade na abrangência geográfica das fontes dos dados. Embora o dataset possua 146 municípios, todos com cobertura do INMET - apenas 86 deles (58,9%) têm estação do CEMADEN e 52 (35,6%) têm estação da ANA/HidroWeb, como mostrado nas tabelas 4 e 5. Esta limitação representa um empecilho na construção do modelo preditivo, dado que os indicadores que estão mais relacionados aos riscos de enchentes (cota_cm e vazao_m3s) estão disponíveis somente para os 52 municípios com cobertura da ANA.
O terceiro *insight* refere-se à correlação entre as variáveis meteorológicas e hidrológicas. De acordo com a figura 9, a correlação entre as variáveis que medem índices pluviométricos PRECIPITAÇÃO TOTAL, HORÁRIO e chuva_cemaden_mm e as que medem índices fluviométricos cota_cm e vazao_m3s é quase zero, mais precisamente, variam entre -0,03 e 0,04. A baixa correlação obtida não invalida a hipótese do projeto, pois o nível do rio aumenta com certo atraso temporal com relação à chuva, e a correlação de Pearson não captura esse detalhe.

Por isso, torna-se evidente a necessidade de coanalisar as séries temporais contidas na Seção 3.4 a fim de identificar o atraso entre os eventos de chuva e os níveis fluviais. Além disso, foi identificada uma correlação moderada de 0,28 entre as fontes provenientes do CEMADEN e INMET, o que faz sentido, uma vez que medem o mesmo fenômeno, porém em estações diferentes. Por último, há uma correlação moderada de 0,44 entre as variáveis cota_cm e vazao_m3s, que é totalmente esperada, dado que medem o mesmo corpo hídrico.

Diante disso, a técnica a ser aplicada na etapa de modelagem a fim de corrigir os dados desbalanceados será a *Oversampling* (sobreamostragem), já que deve-se preservar todos os dados que foram coletados e, então, equilibrar a representação dos eventos de chuva extrema, que são raros, em relação ao dataset todo. A técnica de *Undersampling* (subamostragem) foi desconsiderada com o objetivo de evitar uma perda massiva de dados, uma vez que toda a classe majoritária (sem enchente) seria reduzida à mesma quantidade da classe minoritária (com enchente).

Instruções de Formatação

Os textos devem utilizar páginas de tamanho **A4** (29,7 x 21,0 cm) com **margem superior de 3,3 cm, inferior de 2,5 cm e laterais de 2,9 cm**. Devem ser escritos em coluna única, com fonte ***Times New Roman*** **11**.

Estilo das Citações

As citações no texto devem estar entre colchetes e conter os últimos sobrenomes dos autores, no caso de um ou dois autores, e o último sobrenome seguido de ”et al.” no caso de mais de dois autores, seguidos do ano da publicação, como por exemplo, [Anna 2006], [Gates 2003], [Smith e Jones 2002], [Silva et al. 1999], [Pelé e Romário 2004], [Doe 2016]. As referências no final do texto devem estar em ordem alfabética do último sobrenome do primeiro autor.

Referências

Anna, A. (2006). Artigo em conferência. In *Anais do XXVIII SBPO*, p. 123–134, Rio de Janeiro. SOBRAPO.

Doe, P. (2016). Web page. http://aiweb.techfak.uni-bielefeld.de/content/bworld-robot-control-software/. Acessado: 2016-01-02.

Gates, B. (2003). Um Livro Muito Bom. Editora X, local.

Pelé, E. N. e Romário, R. R. (2004). Exemplo de artigo em livro, em Windows, p. t. e Linux, v. g. (eds.). In CBF e FIFA, editores, Coletânea de Artigos. Editora Y.

Silva, A. B., Souza, C. D. e Santos, E. F. (1999). Título de um relatório técnico. Relatórios de Pesquisa em Engenharia de Produção 4, Universidade Z.

Smith, S. e Jones, J. (2002). A paper on operations research. *Pesquisa Operacional*, 32:5–44.